MODUL 13

CLUSTERING

Clustering adalah seperangkat teknik yang digunakan untuk mempartisi data ke dalam kelompok, atau cluster berdasarkan kemiripan *feature*. *Clustering* sering digunakan sebagai teknik analisis data untuk menemukan pola menarik dalam data, seperti kelompok pelanggan berdasarkan perilaku mereka ataupun melakukan analisis sentiment pada suatu hal.

K-Means adalah salah satu metode clustering. Algoritma K-Means bekerja dengan cara iteratif untuk menemukan kelompok yang optimal. Langkah-langkah umumnya adalah:

1. Inisialisasi centroid awal, yaitu memilih titik-titik awal sebagai centroid untuk setiap cluster. Biasanya dipilih secara random.
2. Assign data ke centroid terdekat.
3. Perbarui centroid untuk setiap cluster.
4. Melakukan iterasi sampai tercapai keadaan konvergen.

Algoritma K-Means dapat diimplementasi dengan sklearn.cluster.KMeans. pada library scikit-learn.

Penggunaan library scikit-learn untuk clustering

1	`# import tools`
	`import numpy as np`
	`import pandas as pd`
	`import matplotlib.pyplot as plt`
	`import seaborn as sns`
	`from sklearn.cluster import KMeans`

2	`# import data`
	`df = pd.read_csv('Mall_Customers.csv')`
	`df.head()`

3	`# amati bentuk data` `df.shape`
4	`# Melihat ringkasan statistik deskriptif dari DataFrame` `......#tambahkan code disini`
5	`# cek null data` `..... #tambahkan code disini`
6	`# cek outlier` `..... #tambahkan code disini`

7	`# amati bentuk visual masing-masing fitur`
	`plt.style.use('fivethirtyeight')`
	`plt.figure(1 , figsize = (15 , 6))`
	`n = 0`

	for x in ['Age' , 'Annual Income (k$)' , 'Spending Score (1-100)']: n += 1 plt.subplot(1 , 3 , n) plt.subplots_adjust(hspace =0.5 , wspace = 0.5) sns.histplot(df[x], kde=True, stat="density", kde_kws=dict(cut=3), bins = 20) plt.title('Distplot of {}'.format(x)) ..... **#tambahkan code disini untuk menampilkan figure**

8	# Ploting untuk mencari relasi antara Age , Annual Income and Spending Score
	plt.figure(1 , figsize = (15 , 20))
	n = 0
	for x in ['Age' , 'Annual Income (k$)' , 'Spending Score (1-100)']:
	  for y in ['Age' , 'Annual Income (k$)' , 'Spending Score (1-100)']:
	  n += 1
	  plt.subplot(3 , 3 , n)
	  plt.subplots_adjust(hspace = 0.5 , wspace = 0.5)
	  sns.regplot(x = x , y = y , data = df)
	  plt.ylabel(y.split()[0]+' '+y.split()[1] if len(y.split()) > 1 else y)
	..... **#tambahkan code disini untuk menampilkan figure**

9	# Melihat sebaran Spending Score dan Annual Income pada Gender
	plt.figure(1 , figsize = (15 , 8))
	for gender in ['Male' , 'Female']:
	  plt.scatter(x = 'Annual Income (k$)',y = 'Spending Score (1-100)' ,
	  data = df[df['Gender'] == gender] ,s = 200 , alpha = 0.5 ,
	  label = gender)
	  plt.xlabel('Annual Income (k$)'), plt.ylabel('Spending Score (1-100)')
	  plt.title('Annual Income vs Spending Score')
	  plt.legend()
	..... **#tambahkan code disini untuk menampilkan figure**

10	# Merancang K-Means untuk spending score vs annual income
	# Menentukan nilai k yang sesuai dengan Elbow-Method
	X1 = df[['Annual Income (k$)' , 'Spending Score (1-100)']].iloc[: , :].values
	inertia = []
	for n in range(1 , 11):
	  algorithm = (KMeans(n_clusters = n ,init='k-means++', n_init = 10,max_iter=300, random_state= 111))

	``
	  algorithm.fit(X1)
	  inertia.append(algorithm.inertia_)
	
	# Plot bentuk visual elbow
	plt.figure(1 , figsize = (15 ,6))
	plt.plot(range(1 , 11) , inertia , 'o')
	plt.plot(range(1 , 11) , inertia , '-' , alpha = 0.5)
	plt.xlabel('Number of Clusters') , plt.ylabel('Inertia')
	..... #tambahkan code disini untuk menampilkan figure
	``

11	```
	# Membangun K-Means
	algorithm = (KMeans(n_clusters = ... # isi nilai n sesuai dengan hasil elbow,init='k-means++', n_init = 10, max_iter=300,
	tol=0.0001, random_state= 111 , algorithm='elkan'))
	algorithm.fit(X1)
	labels2 = algorithm.labels_
	centroids2 = algorithm.cluster_centers_
	``

12	```
	# Menyiapkan data untuk bentuk visual cluster
	labels2 = algorithm.labels_
	centroids2 = algorithm.cluster_centers_
	step = 0.02
	x_min, x_max = X1[:, 0].min() - 1, X1[:, 0].max() + 1
	y_min, y_max = X1[:, 1].min() - 1, X1[:, 1].max() + 1
	xx, yy = np.meshgrid(np.arange(x_min, x_max, step),
	np.arange(y_min, y_max, step))
	Z1 = algorithm.predict(np.c_[xx.ravel(), yy.ravel()]) # array diratakan 1D
	``

13	``` # Melihat bentuk visual cluster plt.figure(1 , figsize = (15 , 7)) plt.clf() Z1 = Z1.reshape(xx.shape) plt.imshow(Z1 , interpolation='nearest', extent=(xx.min(), xx.max(), yy.min(), yy.max()), cmap = plt.cm.Pastel2, aspect = 'auto', origin='lower') plt.scatter(x = 'Annual Income (k$)' ,y = 'Spending Score (1-100)' , data= df , c = labels2 , s = 200) plt.scatter(x = centroids2[: , 0] , y = centroids2[: , 1] , s = 300 , c = 'red' , alpha = 0.5) plt.ylabel('Spending Score (1-100)') , plt.xlabel('Annual Income (k$)') ..... #tambahkan code disini untuk menampilkan figure ```

14	```
	# Melihat nilai Silhouette Score
	score2 = silhouette_score(X1, labels2)
	print("Silhouette Score: ", score2)
	``

Tugas

1. Kerjakan tugas secara kelompok
2. Tambahkan code pada baris-baris yang berisi titik-titik → Kelompok Ganjil dan Genap
3. Buatlah program untuk clustering menggunakan K-Modes → Kelompok Ganjil
4. Buatlah program untuk clustering menggunakan K-Prototype → Kelompok Genap
5. Data bebas tp dalam satu kelas datanya harus sama dan antar kelas tidak boleh sama
6. Buatlah laporan yang terdiri dari print screen hasil dan penjelasannya
7. File yang dikumpulkan data asli, program phyton, dan laporan
8. Tugas terdiri dari Laporan, file phyton, dan data aslinya dan dikumpulkan dengan nama "Tugas Clustering_Kelompok XXX.Zip
9. Tugas dikumpulkan paling lambat hari Senin / 24 Nopember 2025 pukul 23.59 Wib.